

Eksploracyjna analiza skupień klatek z nagrań wideo z kamer samochodowych

Dominik Banach, Marek Kacprzak

Kwiecień 2025

Streszczenie

Celem niniejszego projektu jest eksploracyjna analiza klatek wyodrębnionych z nagrań wideo pochodzących z kamer samochodowych. Skupiono się na górnej części obrazów, zawierającej najczęściej niebo, które może pośrednio odzwierciedlać jakość powietrza. Obrazy zostały przekształcone z przestrzeni RGB do HSV i poddane selekcji oraz redukcji wymiarowości w oparciu o analizę zmienności pikseli. Następnie zastosowano trzy metody klastrowania: KMeans, DBSCAN i hierarchiczną metodę Warda. Najlepsze rezultaty pod względem interpretowalności uzyskano przy podziale na cztery klastry, które odpowiadają różnym warunkom widoczności – takim jak niebieskie niebo, szare niebo, noc/tunel oraz przeszkody. Dominacja klas odpowiadających szarościom może sugerować występowanie zanieczyszczeń powietrza w analizowanym materiale wideo.

1 Wstęp

1.1 Cel i zakres analizy

W dobie rosnącego zainteresowania analizą danych obrazowych oraz rozwojem systemów monitoringu i autonomicznej jazdy, analiza nagrań z kamer samochodowych staje się istotnym narzędziem badawczym. Kamery montowane na pojazdach rejestrują wiele godzin materiałów wideo, które można wykorzystać do detekcji przeszkód, analizy warunków pogodowych czy oceny jakości powietrza. Jednym z podejść do eksploracyjnej analizy takich danych jest analiza skupień (ang. *clustering*), umożliwiająca grupowanie podobnych fragmentów obrazu bez potrzeby nadzoru.

Celem niniejszego projektu jest przeprowadzenie eksploracyjnej analizy skupień na wybranym zbiorze klatek wyodrębnionych z nagrań wideo wykonanych w trakcie jazdy samochodem po Warszawie i jej obrzeżach. Skupiamy się na analizie kolorów występujących w górnej części obrazu, które często odpowiadają niebu lub wysokim zabudowaniom miejskim.

Do analizy zastosowano kilka popularnych metod klastrowania, w tym KMeans, DBSCAN oraz metodę Warda. Wcześniej konieczne było przekształcenie danych z obrazów do postaci wektorów cech, ich selekcja oraz redukcja wymiarowości. Szczególną uwagę poświęcono modelowi barw HSV, który lepiej oddaje percepcyjne różnice kolorów niż klasyczny model RGB.

Analiza pozwala odpowiedzieć na pytanie, czy na podstawie kolorystyki nieba widocznego na nagraniach możliwe jest wykrycie istotnych klas obrazów i czy dominacja

poszczególnych kolorów (np. szarości) może być interpretowana w kontekście zanieczyszczenia powietrza.

1.2 Słownik pojęć

- **RGB (Red, Green, Blue)** – przestrzeń barw oparta na składowych światła czerwonego, zielonego i niebieskiego. Popularna w reprezentacji obrazów w kamerach i monitorach.
- **HSV (Hue, Saturation, Value)** – alternatywna przestrzeń barw lepiej odpowiadająca postrzeganiu kolorów przez człowieka. Składowe opisują barwę (Hue), nasycenie (Saturation) i jasność (Value).
- **KMeans** – popularna metoda klastrowania polegająca na podziale danych na k klastrów w taki sposób, aby minimalizować odległość punktów od środków klastrów.
- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** – algorytm klastrowania wykrywający gęsto zaludnione obszary w danych; nie wymaga podania liczby klastrów i radzi sobie z hałasem.
- **Metoda Warda** – hierarchiczna metoda klastrowania minimalizująca sumę kwadratów różnic wewnątrz klastrów. Pozwala na tworzenie dendrogramów i analizę hierarchicznej struktury danych.
- **Kolor nieba** – istotna cecha wizualna wykorzystywana w analizie warunków atmosferycznych i pośrednio jakości powietrza. Niebieskie niebo może wskazywać na przejrzystą atmosferę, szare – na zachmurzenie lub zanieczyszczenie.
- **Zanieczyszczenia powietrza** – czynniki wpływające na widoczność nieba w kamerach. W analizie skupień mogą prowadzić do występowania określonych klas związanych z obniżoną przejrzystością.

2 Zbiór danych

2.1 Ogólny opis zbioru

Informacje o liczbie godzin nagrań, lokalizacji (np. mapa Warszawy), źródle danych.

2.2 Ekstrakcja klatek

Opis procesu ekstrakcji klatek z nagrań, zmiana rozmiaru obrazów, długość wektora cech.

2.3 Dalsza redukcja wymiarowości

2.3.1 Analiza średniej klatki

Opis analizy średniej klatki, identyfikacja maski i refleksów, decyzja o obcięciu dolnych 20 wierszy.

2.3.2 Analiza współczynnika zmienności (CV)

Analiza współczynnika zmienności pikseli, wybór obszarów z $CV \leq 20\%$, które odpowiadają niebu.

2.3.3 Konwersja na model HSV i statystyki opisowe

Opis konwersji z RGB na HSV, przedstawienie statystyk opisowych zredukowanego zbioru, wizualizacje 2D i 3D.

2.3.4 Propozycja dwóch ostatecznych wektorów cech

Opis dwóch wybranych wektorów cech, które najlepiej sprawdziły się w analizie.

3 Klastrowanie KMeans

3.1 Krótszy wektor cech

Wykres łokciowy, wizualizacje 3D klastrów, przykładowe obrazy z klastrów.

3.2 Dłuższy wektor cech

Brak wykresu łokciowego, wizualizacje klastrów, przykładowe obrazy z klastrów.

3.3 Interpretacja wyników

Interpretacja czterech klastrów: niebieskie niebo, szare niebo, noc/tunel, przeszkody.

4 Klastrowanie DBSCAN

4.1 Wybór parametru eps

Wykres 5NN do wyboru parametru eps.

4.2 Wizualizacje dla różnych wartości MinPts

Wizualizacje klastrowania dla $\text{eps}=0.008$ i różnych wartości MinPts, analiza wyników.

4.3 Porównanie z KMeans

Porównanie podziału na 4 klastry DBSCAN i KMeans, trudności w interpretacji klastrów DBSCAN.

5 Klastrowanie metodą Warda

5.1 Dendrogram

Prezentacja dendrogramu uzyskanego metodą Warda.

5.2 Podziały na 3, 4 i 5 klastrów

Wizualizacje podziałów na różną liczbę klastrów, analiza podobieństw do wyników KMeans.

5.3 Interpretacja i porównanie z KMeans

Interpretacja klastrów uzyskanych metodą Warda, porównanie z wynikami KMeans.

6 Wnioski

Podsumowanie wyników analizy, dominacja szarego nieba, stosunek niebieskiego do szarego nieba, odniesienie do pracy z konferencji EPEC 2024 dotyczącej wpływu zanieczyszczeń na kolor nieba.

Literatura

[1]