

Eksploracyjna analiza skupień klatek z nagrań wideo z kamer samochodowych

Dominik Banach, Marek Kacprzak

Kwiecień 2025

Streszczenie

Celem niniejszego projektu jest eksploracyjna analiza klatek wyodrębnionych z nagrań wideo pochodzących z kamer samochodowych. Skupiono się na górnej części obrazów, zawierającej najczęściej niebo, które może pośrednio odzwierciedlać moment dnia nagrania. Obrazy zostały przekształcone z przestrzeni RGB do HSV i poddane selekcji oraz redukcji wymiarowości w oparciu o analizę zmienności pikseli. Następnie zastosowano trzy metody klastrowania: KMeans, DBSCAN i hierarchiczną metodę Warda. Najlepsze rezultaty pod względem interpretowalności uzyskano przy podziale na cztery klastry, które odpowiadają różnym warunkom widoczności – takim jak niebieskie niebo, szare niebo, noc/tunel oraz przeszkody. Dominacja klas odpowiadających szarościom może sugerować występowanie pory wieczorowej w analizowanym materiale wideo.

1 Wstęp

1.1 Cel i zakres analizy

W dobie rosnącego zainteresowania analizą danych obrazowych oraz rozwojem systemów monitoringu i autonomicznej jazdy, analiza nagrań z kamer samochodowych staje się istotnym narzędziem badawczym. Kamery montowane na pojazdach rejestrują wiele godzin materiałów wideo, które można wykorzystać do detekcji przeszkód, analizy warunków pogodowych czy oceny pory dnia. Jednym z podejść do eksploracyjnej analizy takich danych jest analiza skupień (ang. *clustering*), umożliwiająca grupowanie podobnych fragmentów obrazu bez potrzeby nadzoru.

Celem niniejszego projektu jest przeprowadzenie eksploracyjnej analizy skupień na wybranym zbiorze klatek wyodrębnionych z nagrań wideo wykonanych w trakcie jazdy samochodem po Warszawie i jej obrzeżach. Skupiamy się na analizie kolorów występujących w górnej części obrazu, które często odpowiadają niebu lub wysokim zabudowaniom miejskim.

Do analizy zastosowano kilka popularnych metod klastrowania, w tym KMeans, DBSCAN oraz metodę Warda. Wcześniej konieczne było przekształcenie danych z obrazów do postaci wektorów cech, ich selekcja oraz redukcja wymiarowości. Szczególną uwagę poświęcono modelowi barw HSV, który lepiej oddaje percepcyjne różnice kolorów niż klasyczny model RGB.

Analiza pozwala odpowiedzieć na pytanie, czy na podstawie kolorystyki nieba widocznego na nagraniach możliwe jest wykrycie istotnych klas obrazów i czy dominacja poszczególnych kolorów (np. szarości) może być interpretowana w kontekście gdzie znajdował się samochód wyposażony w kamerę.

1.2 Słownik pojęć

- **RGB (Red, Green, Blue)** – przestrzeń barw oparta na składowych światła czerwonego, zielonego i niebieskiego. Popularna w reprezentacji obrazów w kamerach i monitorach.
- **HSV (Hue, Saturation, Value)** – alternatywna przestrzeń barw lepiej odpowiadająca postrzeganiu kolorów przez człowieka. Składowe opisują barwę (Hue), nasycenie (Saturation) i jasność (Value).
- **KMeans** – popularna metoda klastrowania polegająca na podziale danych na k klastrów w taki sposób, aby minimalizować odległość punktów od środków klastrów.
- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** – algorytm klastrowania wykrywający gęsto zaludnione obszary w danych; nie wymaga podania liczby klastrów i radzi sobie z hałasem.
- **Metoda Warda** – hierarchiczna metoda klastrowania minimalizująca sumę kwadratów różnic wewnątrz klastrów. Pozwala na tworzenie dendrogramów i analizę hierarchicznej struktury danych.
- **Kolor nieba** – istotna cecha wizualna wykorzystywana w analizie warunków atmosferycznych. Niebieskie niebo może wskazywać na dzień, a szare na wieczór.


2 Zbiór danych

2.1 Ogólny opis zbioru

Zbiór danych wykorzystany w niniejszej analizie pochodzi z nagrań wideo zarejestrowanych za pomocą kamery samochodowej podczas przejazdu przez różne części Warszawy. Łącznie analizowany materiał obejmuje około 140 godzin jazdy, zarejestrowanych w różnicowanych warunkach oświetleniowych i pogodowych (np. dni pochmurne, słoneczne, zmierzch, przejazdu przez tunele lub pod estakadami).

Na potrzeby dalszej analizy z nagrań zostały wyodrębnione pojedyncze klatki (60 klatek z sekundy nagrania). Celem było uchwycenie różnorodności scen miejskich widocznych na górnej części obrazu, gdzie – zależnie od otoczenia – może występować niebo, zabudowania, infrastruktura drogowa lub bloki mieszkaniowe.

Trasa przejazdu obejmowała m.in. centrum Warszawy, mosty, dzielnice z gęstą zabudową oraz fragmenty tras szybkiego ruchu



Rysunek 1: Orientacyjna trasa przejazdu samochodu z kamerą.

W początkowej fazie analizy pozyskano łącznie około $60 \times 60 \times 140$ klatek, które następnie poddano przetwarzaniu w celu dalszego modelowania i klastrowania kolorystycznego. Zastosowana metodologia koncentruje się nie na całym obrazie, lecz na jego górnej części, w której najczęściej znajduje się niebo lub elementy go przysłaniające – takie jak budynki, znaki drogowe lub elementy infrastruktury. To właśnie ta część obrazu została uznana za najbardziej reprezentatywną do klastrowania na podstawie kolorystyki sceny.

2.2 Ekstrakcja klatek

Z nagrań wideo pozyskanych z kamery samochodowej wyodrębniono pojedyncze klatki. Proces ekstrakcji został przeprowadzony przy użyciu skryptu automatyzującego odczyt kolejnych ramek z plików wideo oraz zapis ich jako obrazów w formacie `.png`.

Każda z klatek została przeskalowana z oryginalnej rozdzielczości 1920×1080 pikseli do mniejszej, uproszczonej postaci 240×80 piksele, co umożliwiała znaczną redukcję kosztów obliczeniowych przy dalszym przetwarzaniu. Redukcja rozdzielczości była kluczowa z uwagi na fakt, że dalsze etapy analizy wymagały konwersji każdej klatki do wektora cech.

Dla każdej przeskalowanej klatki obliczono wektor cech, w którym każdy piksel był reprezentowany trzema wartościami odpowiadającymi składowym koloru w przestrzeni RGB. Ostatecznie więc pojedynczy obraz o rozmiarze 240×80 zawierał $240 \times 80 = 19.200$ pikseli, a wektor cech miał długość $19.200 \times 3 = 57\,600$ elementów.

Tak otrzymane wektory stanowiły bazę do dalszej redukcji wymiarowości oraz transformacji kolorystycznych, umożliwiających ekstrakcję tylko tych fragmentów obrazu, które były istotne z punktu widzenia analizy kolorystyki nieba lub jego braku.

2.3 Dalsza redukcja wymiarowości


2.3.1 Analiza średniej klatki

Pierwszym krokiem redukcji danych było obliczenie tzw. średniej klatki, czyli uśrednienia wartości pikseli dla wszystkich wyodrębnionych obrazów. Celem tego zabiegu była identyfikacja wspólnych, statycznych elementów występujących w większości klatek, które nie niosą dodatkowej informacji istotnej dla klastrowania.

W wyniku analizy zaobserwowano wyraźną obecność odbić deski rozdzielczej oraz maski samochodu w dolnej części obrazów. Te elementy występowały regularnie i stanowiły silnie powtarzalny wzorec, który mógłby zdominować dalszą analizę skupień. Na podstawie obserwacji średniej klatki zdecydowano się na obcięcie dolnych 20 wierszy obrazu, co odpowiadało około jednej trzeciej jego wysokości.

Tym samym analizowany fragment każdej klatki został ograniczony do wymiaru 240×60 piksele, co odpowiadało nowemu wektorowi cech o długości $240 \cdot 60 \cdot 3 = 43\,200$ elementów w przestrzeni RGB.

Średnia klatka



Rysunek 2: Obraz średniej klatki – widoczne powtarzalne elementy w dolnej części (maska, deska rozdzielcza).

2.3.2 Analiza współczynnika zmienności (CV)

Kolejnym etapem redukcji liczby cech była analiza współczynnika zmienności (*Coefficient of Variation*, CV) dla każdego piksela w analizowanej przestrzeni obrazu. Współczynnik CV został obliczony osobno dla każdej składowej koloru RGB na podstawie wszystkich wyodrębnionych klatek, według wzoru:

$$CV = \frac{\sigma}{\mu}$$

gdzie σ to odchylenie standardowe danego piksela w czasie, a μ to jego średnia wartość.

Na podstawie wyników analizy CV zauważono, że obszary o niskiej zmienności ($CV \leq 20\%$) występowały głównie w górnej części obrazu i pokrywały się z miejscami, w których zazwyczaj znajduje się niebo. Piksele te charakteryzują się dużą stabilnością w czasie – niezależnie od warunków atmosferycznych lub pozycji pojazdu.

W związku z tym zdefiniowano maskę, która wybiera tylko te piksele, których CV dla przynajmniej jednej składowej RGB nie przekraczało 20%. Taka selekcja pozwoliła ograniczyć liczbę cech z 9792 do około ~ 3500 (wartość zależna od liczby wybranych pikseli). Dzięki temu uzyskano tzw. **krótszy wektor cech**, który okazał się szczególnie przydatny w dalszych eksperymentach z klastrowaniem.




Rysunek 3: Maska pikseli z $CV \leq 20\%$, odpowiadających zazwyczaj niebu.

2.3.3 Konwersja na model HSV i przegląd statystyk opisowych

Po zastosowaniu redukcji opartej na współczynniku zmienności, dla wybranych pikseli dokonano konwersji przestrzeni barw z modelu RGB na HSV (ang. *Hue*, *Saturation*, *Value*). Model HSV uznawany jest za bardziej intuicyjny z punktu widzenia percepcji barw przez człowieka, ponieważ oddziela informację o barwie od jasności i nasycenia.

Proces konwersji został przeprowadzony dla każdego piksela wewnątrz maski $CV \leq 20\%$, osobno dla kanałów H, S i V. Przykładowa konwersja pojedynczego piksela z RGB na HSV została wykonana według standardowego algorytmu dostępnego w bibliotece OpenCV¹.


Na potrzeby eksploracji rozkładów cech utworzono zestawienie statystyk opisowych (średnia, mediana, odchylenie standardowe) dla każdego z trzech kanałów HSV, a także przeprowadzono analizę rozkładów przy użyciu histogramów (zarówno w skali liniowej, jak i logarytmicznej).



Rysunek 4: Histogram wartości kanału **Hue** w skali liniowej (lewo) i logarytmicznej (prawo).

Dodatkowo przygotowano wizualizacje rozkładów punktów w przestrzeniach 2D i 3D. Na wykresach tych widoczne są zagęszczenia odpowiadające charakterystycznym kolorom nieba – np. skupiska w obszarach błękitu oraz neutralnych szarości.

¹https://docs.opencv.org/4.x/df/d9d/tutorial_py_colorspaces.html



Rysunek 5: Lewo: rozrzut punktów w przestrzeni H-S. Prawo: wizualizacja 3D w przestrzeni HSV.

Dzięki transformacji na HSV możliwe stało się bardziej intuicyjne porównanie odcieni oraz klasyfikacja scen pod kątem dominujących barw. Informacja o jasności (V) i nasyceniu (S) okazała się pomocna w odróżnianiu typowych scen nieba od tych z dominacją szarości lub zaciemnienia.

2.3.4 Propozycja dwóch ostatecznych wektorów cech

W toku eksploracji przygotowano kilka różnych reprezentacji cech, bazujących na przekształconych danych HSV oraz maskach wybranych pikseli. Celem było znalezienie takich wektorów cech, które:

- zawierają istotną informację różnicującą sceny,
- mają możliwie niską liczbę wymiarów,
- pozwalają na uzyskanie dobrze separowalnych klastrów.

Spośród przetestowanych wariantów, dwa wektory cech okazały się najbardziej efektywne w dalszej analizie skupień:

1. **Krótszy wektor HSV (CV-filtered)** – zawiera wartości HSV tylko dla pikseli spełniających warunek $CV \leq 20\%$, po wcześniejszym obcięciu dolnych 20 wierszy obrazu. Długość wektora cech po tej operacji wynosiła od około 3300 do 3800 (zależnie od liczby pikseli wybranych przez maskę).
2. **Dłuższy wektor HSV (pełny górny obszar)** – zawiera wszystkie piksele z górnych 34 rzędów obrazu ($96 \cdot 34 = 3264$ pikseli), każdy reprezentowany w przestrzeni HSV (czyli łącznie $3264 \cdot 3 = 9792$ elementów).

Oba wektory zostały wykorzystane w dalszych eksperymentach z klastrowaniem. Pierwszy z nich – krótszy – dawał bardziej przejrzyste i spójne klastry, a także mniejsze zapotrzebowanie obliczeniowe. Drugi natomiast pozwalał uwzględnić szerszy kontekst kolorystyczny obrazu, kosztem większego szumu i trudniejszej interpretacji wyników.


W kolejnych rozdziałach oba wektory zostaną wykorzystane do klastrowania metodą KMeans, natomiast krótszy wektor – jako bardziej reprezentatywny – został również zastosowany w algorytmach DBSCAN oraz metody Warda.

3 Klastrowanie KMeans

3.1 Klastrowanie względem krótszego wektora cech i wizualizacje wyników


Do pierwszego eksperymentu klastrowania zastosowano algorytm KMeans dla krótszego wektora cech, zawierającego tylko wartości HSV dla pikseli o współczynniku zmienności $CV \leq 20\%$. Dane te były najbardziej zwarte, jednorodne i dobrze odwzorowywały kolorystykę nieba widoczną w górnej części obrazu.

Aby wyznaczyć optymalną liczbę klastrów k , przeprowadzono analizę wykresu łokciowego (ang. *elbow plot*), który przedstawia sumę kwadratów błędów (inertia) w zależności od liczby klastrów. Punkt załamania wskazywał na wartość $k = 4$ jako najlepszy kompromis między precyzją a prostotą modelu.




Rysunek 6: Wykres łokciowy wskazujący optymalną liczbę klastrów $k = 4$ dla krótszego wektora cech.

Po wybraniu $k = 4$, algorytm został uruchomiony ponownie w celu przypisania każdej klatki do jednego z czterech klastrów. Do wizualizacji wyników zastosowano redukcję wymiarów (np. PCA lub t-SNE), dzięki czemu możliwe było przedstawienie podziału klatek w przestrzeni 3D.



Rysunek 7: Wizualizacja klastrów KMeans ($k = 4$) w przestrzeni zredukowanej do trzech wymiarów.

Każdy z klastrów zawierał obrazy o charakterystycznych cechach kolorystycznych. W celu jakościowej oceny wyników zaprezentowano losowe próbki klatek z każdego klastra. Przykładowe obrazy zostały przedstawione poniżej:



Rysunek 8: Przykładowe klatki przypisane do poszczególnych klastrów ($k = 4$).

Wyniki sugerują, że KMeans skutecznie wydzielił klastry odpowiadające różnym typom scen:


- niebieskie, bezchmurne niebo,
- szare niebo lub warstwa chmur,
- ciemne ujęcia (np. tunel, zmierzch, cień),
- sceny z zabudowaniami lub przeszkodami w górnej części obrazu.

3.2 Klastrowanie względem dłuższego wektora cech

W kolejnym eksperymencie zastosowano algorytm KMeans dla tzw. dłuższego wektora cech – zawierającego wartości HSV dla wszystkich pikseli w górnej części obrazu (96×34 piksele, czyli 9792 wartości). W przeciwieństwie do wcześniejszego wariantu nie stosowano tutaj maski CV, co pozwalało uwzględnić więcej informacji z otoczenia, ale również zwiększało ryzyko wprowadzenia szumu do modelu.

Z powodu wysokiego wymiaru i większej złożoności danych nie wykonano ponownie analizy wykresu łokciowego – założono $k = 4$ dla spójności porównawczej z poprzednim podejściem.


Podobnie jak wcześniej, przeprowadzono redukcję wymiarowości do trzech składowych i dokonano wizualizacji przestrzennej klastrów. W tym przypadku granice między klastrami okazały się mniej wyraźne, a rozkład danych bardziej rozproszony.



Rysunek 9: Wizualizacja klastrów KMeans ($k = 4$) dla dłuższego wektora cech. Przestrzeń po redukcji wymiarowości.

Również w tym podejściu zaprezentowano przykładowe klatki z każdego klastra. Choć klastry nadal wykazywały pewną spójność, ich interpretacja była trudniejsza. Część klatek zawierała mieszane typy scen – np. fragment nieba częściowo przysłonięty zabudową – co utrudniało jednoznaczne przypisanie do konkretnej klasy.

Trudne do interpretacji klastry



Rysunek 10: Przykładowe klatki przypisane do klastrów KMeans dla dłuższego wektora cech.

W porównaniu do wersji z krótszym wektorem, rezultaty uzyskane przy wykorzystaniu pełnej górnej części obrazu cechowały się niższą czytelnością. Zwiększona liczba cech mogła przyczynić się do nadmiernego dopasowania do szumu i mniejszej separowalności wizualnej poszczególnych klas.

3.3 Interpretacja wyników

Wyniki klastrowania metodą KMeans dla obu wektorów cech – krótszego (filtrowanego maską CV) i dłuższego (pełna górna część obrazu) – pozwalają na wysnucie kilku istotnych obserwacji.

W przypadku **krótszego wektora**, klastry okazały się wyraźnie separowalne, a ich zawartość dała się jednoznacznie przypisać do określonych typów scen. Szczególnie dobrze widoczny był podział na cztery dominujące klasy:

1. **Niebieskie niebo** – jasne, dobrze nasyczone odcienie błękitu w górnej części obrazu.
2. **Szare niebo / chmury** – sceny z jednolitym, przytłumionym kolorem górnej części obrazu.
3. **Noc / tunel / cień** – sceny o bardzo niskiej jasności i nasyceniu.
4. **Zabudowania / przeszkody** – brak nieba lub jego częściowe zasłonięcie przez budynki, znaki, mosty itp.

Dzięki uprzedniej selekcji pikseli o niskiej zmienności udało się wyizolować regiony istotne dla klasyfikacji kolorystyki nieba, co skutkowało spójnymi i łatwymi do zinterpretowania klastrami.

Dla **dłuższego wektora cech**, mimo tej samej liczby klastrów ($k = 4$), wyniki były mniej jednoznaczne. Granice między klastrami były rozmyte, a sceny należące do jednego

klastra często znacznie różniły się od siebie wizualnie. Obecność elementów tła, które nie były związane z analizowanym celem (np. fragmenty budynków, znaki, słupy), mogła wprowadzać szum i zaburzać interpretację.

Podsumowując:

- krótszy wektor cech umożliwia efektywniejsze grupowanie scen pod kątem dominującego koloru nieba,
- klastry są wyraźnie zróżnicowane i mogą być jednoznacznie opisane,
- dłuższy wektor zawierał więcej informacji, ale niekoniecznie użytecznej – co skutkowało słabszą separowalnością.


4 Klastrowanie DBSCAN

4.1 Wybór parametru eps na podstawie wykresu 5NN

Do kolejnego etapu analizy skupień wykorzystano algorytm DBSCAN (ang. *Density-Based Spatial Clustering of Applications with Noise*), który w odróżnieniu od KMeans nie wymaga określenia liczby klastrów i potrafi wykrywać obszary o zmiennej gęstości oraz odrzucać punkty szumowe.

Z racji wysokiej złożoności obliczeniowej i dużej liczby cech, klastrowanie DBSCAN przeprowadzono wyłącznie dla krótszego wektora HSV (z zastosowaną maską CV).

Aby dobrać optymalną wartość parametru eps (promień sąsiedztwa), posłużono się wykresem odległości do 5 najbliższych sąsiadów dla każdego punktu (tzw. *5NN-distance plot*). Na wykresie tym obserwuje się moment gwałtownego „przejścia” – załamanie, które sugeruje sensowną wartość eps . W naszym przypadku punkt ten występował w okolicach wartości $eps \approx 0.008$.




Rysunek 11: Wykres 5NN – odległości do piątego najbliższego sąsiada dla wszystkich punktów. Załamanie sugeruje wybór $eps \approx 0,008$.

Dla wybranego $eps = 0.008$ przeprowadzono dalsze eksperymenty z różnymi wartościami parametru $MinPts$, określającego minimalną liczbę punktów w sąsiedztwie wymaganych do uznania punktu za „rdzeniowy”.

4.2 Wizualizacje klastrowania dla $eps = 0.008$ i różnych wartości $MinPts$

Po wyznaczeniu wartości $eps = 0.008$ przeprowadzono serię eksperymentów z różnymi ustawieniami parametru $MinPts$, testując wartości od 4 do 10. Dla każdej konfiguracji wykonano klastrowanie oraz przygotowano wizualizacje rozkładu klastrów w przestrzeni 2D po redukcji wymiarów (np. metodą PCA lub t-SNE).



Rysunek 12: Przykładowe wyniki DBSCAN dla $eps = 0.008$ i różnych wartości $MinPts$. Widoczny silny wpływ parametrów na strukturę klastrów.

Niestety, niezależnie od wybranej wartości $MinPts$, wyniki DBSCAN nie dawały satysfakcjonujących podziałów. W większości przypadków:

- liczba klastrów była bardzo mała (często tylko 2),
- wiele punktów zostało oznaczonych jako szum (outliers),
- brakowało klas, które odpowiadałyby logicznym podziałom zauważonym wcześniej przy użyciu KMeans.

Choć metoda DBSCAN posiada zdolność do wykrywania nieliniowych struktur i pomijania punktów odstających, w kontekście tej analizy – bazującej na subtelnych różnicach kolorystycznych – nie udało się uzyskać klastrów o sensownej interpretacji wizualnej.

4.3 Porównanie podziału na 4 klastry DBSCAN i 4Means

W celu porównania skuteczności obu podejść zestawiono wyniki klastrowania DBSCAN (dla $eps = 0.008$ i różnych $MinPts$) z wcześniej uzyskanym podziałem na 4 klastry przy użyciu algorytmu KMeans (dla krótszego wektora cech).

Podczas gdy KMeans pozwolił na uzyskanie klas, które dało się intuicyjnie zinterpretować jako:

- niebieskie niebo,
- szare niebo,
- ciemne sceny (noc, tunel),
- sceny z przesłonięciem górnej części obrazu,

to w przypadku DBSCAN taka interpretacja była praktycznie niemożliwa.



Rysunek 13: Porównanie klastrów DBSCAN (lewo) i KMeans (prawo) przy $k = 4$. Widać znacznie lepszą separowalność w przypadku KMeans.

DBSCAN, mimo wielu prób, generował albo bardzo ogólne, albo zupełnie przypadkowe klastry. Dodatkowo duża liczba punktów była traktowana jako szum, co zmniejszało wartość poznawczą wyniku. Próby znalezienia czterech dobrze rozpoznawalnych klastrów – analogicznie jak w KMeans – zakończyły się niepowodzeniem.

Z tego względu uznano, że algorytm DBSCAN nie nadaje się w tym przypadku jako główna metoda klastrowania scen na podstawie kolorystyki nieba. Został potraktowany wyłącznie jako uzupełnienie eksploracji, potwierdzające skuteczność klasycznego podejścia centroidowego.

5 Klastrowanie metodą Warda


5.1 Dendrogram

Kolejną metodą klastrowania zastosowaną w projekcie była metoda Warda – jedno z podejść hierarchicznego grupowania aglomeracyjnego. W przeciwieństwie do metod takich jak KMeans, algorytmy hierarchiczne nie wymagają wcześniejszego określenia liczby klastrów – zamiast tego budują drzewiastą strukturę zwaną dendrogramem, która pozwala na analizę danych na różnych poziomach szczegółowości.

Metoda Warda minimalizuje przyrost całkowitej wariancji wewnątrz klastrów przy każdym kolejnym połączeniu. Dzięki temu faworyzuje zwarte, kuliste klastry, podobnie jak KMeans.

Analiza została przeprowadzona dla krótszego wektora cech (czyli HSV tylko dla pikseli o niskim CV), z ograniczoną próbą danych ze względu na złożoność obliczeniową (np. podpróbka 1000 obserwacji).

Wynik przedstawiono w postaci dendrogramu:




Rysunek 14: Dendrogram wygenerowany metodą Warda na bazie krótszego wektora HSV. Widoczne naturalne punkty podziału na 3–5 klastrów.

Wysokość przecięcia drzewa odpowiada liczbie klastrów. Na podstawie wykresu uznano, że podziały na 3, 4 i 5 klastrów są najbardziej sensowne i zostały przeanalizowane w kolejnych krokach.

5.2 Wizualizacje podziałów na 3, 4 i 5 klastrów


Na podstawie dendrogramu utworzonego metodą Warda dokonano trzech różnych cięć drzewa, uzyskując odpowiednio 3, 4 i 5 klastrów. Dla każdej liczby klastrów wykonano redukcję wymiarowości (PCA) w celu wizualizacji podziału w przestrzeni 2D oraz zaprezentowano próbki klatek przypisanych do poszczególnych grup.

Podział na 3 klastry skutkował zbyt ogólnym podziałem – klastry łączyły ze sobą sceny o zbliżonej jasności, ale różnej treści. Przykładowo: niebo i powierzchnie zabudowań o podobnym kolorze trafiały do jednego klastra, co utrudniało ich rozróżnienie.




Rysunek 15: Wizualizacja podziału na 3 klastry metodą Warda. Podział zbyt ogólny – zlewanie się nieba i zabudowań.

Podział na 4 klastry dał najlepsze rezultaty – klastry były wizualnie zbliżone do tych uzyskanych przy użyciu KMeans. Widoczne były grupy odpowiadające niebieskiemu niebu, szaremu niebu, ciemnym scenom (np. tunelom) oraz zabudowaniom. Różnicą w porównaniu do KMeans był fakt, że część ciemnych ujęć została wchłonięta do klastra o innej dominującej kolorystyce.



Rysunek 16: Wizualizacja podziału na 4 klastry metodą Warda. Podział najbardziej zbliżony do KMeans, ale z lekkimi przesunięciami.

Podział na 5 klastrów wprowadzał dodatkowy podział wśród klas już wcześniej sensownie wydzielonych. Efektem było m.in. rozdzielenie nieba na bardziej i mniej nasycone odcienie, jednak kosztem spójności interpretacyjnej i wzrostu złożoności analizy.



Rysunek 17: Wizualizacja podziału na 5 klastrów – wzrost szczegółowości, ale mniejsza interpretowalność.

5.3 Interpretacja i porównanie z 4Means

Porównując wyniki klastrowania metodą Warda (dla $k = 4$) z rezultatami algorytmu KMeans przy tej samej liczbie klastrów, zauważamy znaczące podobieństwa, a jednocześnie istotne różnice w strukturze grup.

W obu przypadkach:

- wyodrębniono klastry odpowiadające **niebieskiemu niebu**, **szaremu niebu**, **ciemnym scenom (noc/tunel)** oraz **scenom przesłoniętym (budynki, infrastruktura)**,
- podział danych był względnie równomierny, a klastry miały sensowną reprezentację wizualną,
- klasy były separowalne w przestrzeni po redukcji wymiarowości.

Różnice pojawiły się natomiast na poziomie szczegółów:

- w metodzie Warda część **ciemnych klatek** została przypisana do klastra z szarym niebem lub zabudowaniami, co może wynikać z podobieństw w jasności i nasyceniu tych scen,
- KMeans – dzięki losowej inicjalizacji – lepiej rozdzielił fragmenty o zbliżonych barwach, ale różnym kontekście,

- metoda Warda – jako podejście deterministyczne i hierarchiczne – wydaje się bardziej „konserwatywna” i mniej wrażliwa na lokalne fluktuacje kolorystyczne.



Rysunek 18: Porównanie klastrów uzyskanych metodą Warda i KMeans dla $k = 4$. Zbliżona struktura, z różnicami w klasyfikacji ciemnych scen.

Podsumowując, klastrowanie hierarchiczne metodą Warda potwierdziło podział scen obserwowany wcześniej w KMeans, ale pokazało również, że niektóre klastry mają nieostre granice – zwłaszcza te odpowiadające scenom zacienionym lub nocnym. Mimo tych różnic, oba podejścia prowadzą do spójnego i interpretowalnego podziału scen na podstawie cech kolorystycznych.

6 Podsumowanie

W niniejszym projekcie przeprowadzono eksploracyjną analizę klatek wyodrębnionych z nagrań wideo z kamer samochodowych, skupiając się na górnej części obrazów. Zastosowano różne metody klastrowania, z których najlepsze rezultaty dała metoda KMeans i metoda Warda z podziałem na 4 klastry.

Najbardziej wartościowe okazało się podejście oparte na:

- selekcji pikseli o niskiej zmienności ($CV \leq 20\%$),
- konwersji do przestrzeni barw HSV,
- klastrowaniu z użyciem algorytmu KMeans przy liczbie klastrów $k = 4$.

Taki podział umożliwił wyróżnienie czterech głównych typów scen:

1. niebieskie niebo,
2. szare niebo / chmury,
3. ciemne ujęcia (np. tunel, zmierzch),
4. fragmenty przesłonięte przez zabudowania lub infrastrukturę.

Klastry odpowiadają różnym warunkom widoczności, takim jak niebieskie niebo, szare niebo, noc/tunel oraz przeszkody. Dominacja klas odpowiadających szarościom może sugerować występowanie pory wieczorowej w analizowanym materiale.