

Eksploracyjna analiza skupień klatek z nagrań wideo z kamer samochodowych

Dominik Banach, Marek Kacprzak

Kwiecień 2025

Streszczenie

Celem niniejszego projektu jest eksploracyjna analiza klatek wyodrębnionych z nagrań wideo pochodzących z kamer samochodowych. Skupiono się na górnej części obrazów, zawierającej najczęściej niebo, które może pośrednio odzwierciedlać moment dnia nagrania. Obrazy zostały przekształcone z przestrzeni RGB do HSV i poddane selekcji oraz redukcji wymiarowości w oparciu o analizę zmienności pikseli. Następnie zastosowano trzy metody klastrowania: KMeans, DBSCAN i hierarchiczną metodę Warda. Najlepsze rezultaty pod względem interpretowalności uzyskano przy podziale na cztery klastry, które odpowiadają różnym kolorom interesujących nas pikseli – takim jak niebieskie niebo, szare niebo, noc/tunel oraz przeszkody.

1 Wstęp

1.1 Cel i zakres analizy

W dobie rosnącego zainteresowania analizą danych obrazowych oraz rozwojem systemów monitoringu i autonomicznej jazdy, analiza nagrań z kamer samochodowych staje się istotnym narzędziem badawczym. Kamery montowane na pojazdach rejestrują wiele godzin materiałów wideo, które można wykorzystać do detekcji przeszkód, analizy warunków pogodowych czy oceny stopnia zakorkowania dróg. Jednym z podejść do eksploracyjnej analizy takich danych jest analiza skupień (ang. *clustering*), umożliwiająca grupowanie podobnych fragmentów obrazu bez potrzeby nadzoru.

Celem projektu jest przeprowadzenie eksploracyjnej analizy skupień na wybranym zbiorze klatek wyodrębnionych z nagrań wideo wykonanych w trakcie jazdy samochodem po Warszawie i jej obrzeżach. Skupiamy się na analizie kolorów występujących w górnej części obrazu, które często odpowiadają niebu lub wysokim zabudowaniom miejskim.

Do analizy zastosowano kilka popularnych metod klastrowania, w tym KMeans, DBSCAN oraz metodę Warda. Wcześniej konieczne było przekształcenie danych z obrazów do postaci wektorów cech, ich selekcja oraz redukcja wymiarowości. Szczególną uwagę poświęcono modelowi barw HSV, który lepiej oddaje percepcyjne różnice kolorów niż klasyczny model RGB.

Analiza pozwala odpowiedzieć na pytanie, czy na podstawie kolorystyki nieba widocznego na nagraniach możliwe jest wykrycie istotnych klas obrazów i czy dominacja poszczególnych kolorów (np. szarości czy czerni) może być interpretowana w kontekście gdzie znajdował się samochód wyposażony w kamerę.

1.2 Słownik pojęć

- **RGB (Red, Green, Blue)** – przestrzeń barw oparta na składowych światła czerwonego, zielonego i niebieskiego. Popularna w reprezentacji obrazów w kamerach i monitorach.
- **HSV (Hue, Saturation, Value)** – alternatywna przestrzeń barw lepiej odpowiadająca postrzeganiu kolorów przez człowieka. Składowe opisują barwę (Hue), nasycenie (Saturation) i jasność (Value).
- **KMeans** – popularna metoda klastrowania polegająca na podziale danych na k klastrów w taki sposób, aby minimalizować odległość punktów od środków klastrów.
- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** – algorytm klastrowania wykrywający gęsto zaludnione obszary w danych; nie wymaga podania liczby klastrów i radzi sobie z hałasem.
- **Metoda Warda** – hierarchiczna metoda klastrowania minimalizująca sumę kwadratów różnic wewnątrz klastrów. Pozwala na tworzenie dendrogramów i analizę hierarchicznej struktury danych.
- **Kolor nieba** – istotna cecha wizualna wykorzystywana w analizie warunków atmosferycznych. Niebieskie niebo może wskazywać na dzień, a szare na wieczór.


2 Zbiór danych

2.1 Ogólny opis zbioru

Zbiór danych wykorzystany w niniejszej analizie pochodzi z nagrań wideo zarejestrowanych za pomocą kamery samochodowej podczas przejazdu przez różne części Warszawy. Łącznie analizowany materiał obejmuje około 140 godzin jazdy, zarejestrowanych w zróżnicowanych warunkach oświetleniowych i pogodowych (np. dni pochmurne, słoneczne, zmierzch, przejazdu przez tunele lub pod estakadami).

Na potrzeby dalszej analizy z nagrań zostały wyodrębnione pojedyncze klatki (60 klatek z sekundy nagrania). Celem było uchwycenie różnorodności scen miejskich widocznych na górnej części obrazu, gdzie – zależnie od otoczenia – może występować niebo, zabudowania, infrastruktura drogowa lub bloki mieszkaniowe.

Trasa przejazdu obejmowała m.in. centrum Warszawy, mosty, dzielnice z gęstą zabudową oraz fragmenty tras szybkiego ruchu



Rysunek 1: Orientacyjna trasa przejazdu samochodu z kamerą.

W początkowej fazie analizy pozyskano łącznie około 6.2 miliona klatek, które następnie poddano przetwarzaniu w celu dalszego modelowania i klastrowania kolorystycznego. Zastosowana metodologia koncentruje się nie na całym obrazie, lecz na jego górnej części, w której najczęściej znajduje się niebo lub elementy go przysłaniające – takie jak budynki, znaki drogowe lub elementy infrastruktury. To właśnie ta część obrazu została uznana za najbardziej reprezentatywną do klastrowania na podstawie kolorystyki sceny.

2.2 Ekstrakcja klatek

Z nagrań wideo pozyskanych z kamery samochodowej wyodrębniono pojedyncze klatki, po 60 na sekundę nagrania. Proces ekstrakcji został przeprowadzony przy użyciu skryptu automatyzującego odczyt kolejnych ramek z plików wideo oraz zapis ich jako obrazów w formacie .png.

Każda z klatek została przeskalowana (licząc średnią z każdych usuniętych klatek w jedną) z oryginalnej rozdzielczości 1920×1080 pikseli do mniejszej, uproszczonej postaci 240×80 piksele, co umożliwiało znaczną redukcję kosztów obliczeniowych przy dalszym przetwarzaniu. Redukcja rozdzielczości była kluczowa z uwagi na fakt, że dalsze etapy analizy wymagały konwersji każdej klatki do wektora cech.

Dla każdej przeskalowanej klatki obliczono wektor cech, w którym każdy piksel był reprezentowany trzema wartościami odpowiadającymi składowym koloru w przestrzeni RGB. Ostatecznie więc pojedynczy obraz o rozmiarze 240×80 zawierał $240 \times 80 = 19.200$ pikseli, a wektor cech miał długość $19.200 \times 3 = 57\,600$ elementów.

Tak otrzymane wektory stanowiły bazę do dalszej redukcji wymiarowości oraz trans-

formacji kolorystycznych, umożliwiających ekstrakcję tylko tych fragmentów obrazu, które były istotne z punktu widzenia analizy kolorystyki nieba lub jego braku.


2.2.1 Analiza średniej klatki

Pierwszym krokiem redukcji danych było obliczenie tzw. średniej klatki, czyli uśrednienia wartości pikseli dla wszystkich wyodrębnionych obrazów. Celem tego zabiegu była identyfikacja wspólnych, statycznych elementów występujących w większości klatek, które nie niosą dodatkowej informacji istotnej dla klastrowania.

W wyniku analizy zaobserwowano wyraźną obecność odbić deski rozdzielczej oraz maski samochodu w dolnej części obrazów. Te elementy występowały regularnie i stanowiły silnie powtarzalny wzorec, który mógłby zdominować dalszą analizę skupień. Na podstawie obserwacji średniej klatki zdecydowano się na obcięcie dolnych 20 wierszy obrazu, co odpowiadało około jednej trzeciej jego wysokości.

Tym samym analizowany fragment każdej klatki został ograniczony do wymiaru 240×60 piksele, co odpowiadało nowemu wektorowi cech o długości $240 \cdot 60 \cdot 3 = 43\,200$ elementów w przestrzeni RGB.

Średnia klatka



Rysunek 2: Obraz średniej klatki – widoczne powtarzalne elementy w dolnej części (maska, deska rozdzielcza).

2.2.2 Analiza współczynnika zmienności (CV)

Kolejnym etapem redukcji liczby cech była analiza współczynnika zmienności (*Coefficient of Variation*, CV) dla każdego piksela w analizowanej przestrzeni obrazu. Współczynnik CV został obliczony osobno dla każdej składowej koloru RGB na podstawie wszystkich wyodrębnionych klatek, według wzoru:

$$CV = \frac{\sigma}{\mu}$$

gdzie σ to odchylenie standardowe danego piksela w czasie, a μ to jego średnia wartość.

Na podstawie wyników analizy CV zauważono, że obszary o niskiej zmienności ($CV \leq 20\%$) występowały głównie w górnej części obrazu i pokrywały się z miejscami, w których zazwyczaj znajduje się niebo. Piksele te charakteryzują się dużą stabilnością w czasie – niezależnie od warunków atmosferycznych lub pozycji pojazdu.

W związku z tym zdefiniowano maskę, która wybiera tylko te piksele, których CV dla przynajmniej jednej składowej RGB nie przekraczało 20%. Taka selekcja pozwoliła ograniczyć liczbę cech do około ~ 930 (wartość zależna od liczby wybranych pikseli). Dzięki temu uzyskano tzw. **krótszy wektor cech**, który okazał się szczególnie przydatny w dalszych eksperymentach z klastrowaniem.



Rysunek 3: Maska pikseli z $CV \leq 20\%$, odpowiadających zazwyczaj niebu.

2.2.3 Definicja ostatecznych wektorów cech

Po przeprowadzeniu analizy CV oraz konwersji kolorów do przestrzeni HSV, sformułowano dwie zwarte reprezentacje cech, które posłużyły do eksperymentów klastrowych. Oba wektory mają istotnie mniejszy wymiar niż surowy obraz, co umożliwia szybkie przetwarzanie i redukcję szumu.

Pierwszy wektor cech $\vec{f}_1$ o długości 7 zawiera podstawowe statystyki opisowe oraz wskaźniki kolorystyczne:

$$\vec{f}_1 = \left[\bar{V}, \sigma_V, \text{IQR}_{RGB}, \frac{G}{R}, \frac{G}{B}, \bar{S}, \bar{H} \right]$$

Gdzie:

- $\bar{V}$ – średnia wartość jasności (Value),
- σ_V – odchylenie standardowe jasności,
- IQR_{RGB} – rozstęp międzykwartyłowy wartości z kanałów R, G, B,
- $\frac{G}{R}, \frac{G}{B}$ – stosunki wartości zielonego kanału do czerwonego i niebieskiego,
- $\bar{S}, \bar{H}$ – średnie wartości nasycenia (Saturation) i barwy (Hue).

Drugi wektor cech $\vec{f}_2$ to minimalna, trzywymiarowa reprezentacja:

$$\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$$

Gdzie:

- $\tilde{H}$ – mediana barwy (Hue),
- $\tilde{S}$ – mediana nasycenia (Saturation),
- $\tilde{V}$ – mediana jasności (Value).

Oba wektory zostały następnie wykorzystane jako reprezentacja cech w eksperymentach z algorytmem KMeans. Wektor $\vec{f}_2$, mimo że krótszy, zapewniał zaskakująco dobrą separowalność w niektórych przypadkach, jednak to $\vec{f}_1$ dawał bardziej stabilne i interpretowalne klastry.

2.2.4 Wizualizacja przestrzeni cech


Aby lepiej zrozumieć rozkład danych w przestrzeni trójwymiarowej $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$, przygotowano serię wykresów przedstawiających strukturę danych z różnych perspektyw.

Górna część Rysunku 4 przedstawia sześć ujęć 3D z różnych azymutów (kątown obrotu wokół osi pionowej), wszystkie przy tej samej elewacji (kąt nachylenia równy 30°). Dzięki temu można dostrzec zagęszczenia punktów, ich strukturę oraz sposób, w jaki dane „układają się” w przestrzeni.

- Dane tworzą kilka charakterystycznych skupień, szczególnie widocznych w okolicach wysokiej jasności (duże wartości $\tilde{V}$) oraz niskiego nasycenia.
- Obszary odpowiadające wyższym wartościom $\tilde{H}$ (barwa) i $\tilde{S}$ (nasycenie) są mniej gęste, co może sugerować rzadsze występowanie żywych barw – zgodne z dominacją szarości w nagraniach.

Dolna część rysunku pokazuje rzuty 2D: pary zmiennych w układach $\tilde{H}$ vs $\tilde{S}$, $\tilde{H}$ vs $\tilde{V}$ oraz $\tilde{S}$ vs $\tilde{V}$. Na ich podstawie można zauważyć:

- Istnienie pionowych pasm w układzie $\tilde{H}$ vs $\tilde{S}$, co sugeruje skokowo zmieniające się nasycenie przy ustalonej barwie (np. granica pomiędzy szarością a błękitem).
- Wartości $\tilde{V}$ są silnie zróżnicowane – obecne są zarówno bardzo jasne, jak i bardzo ciemne próbki, co pokrywa się z rejestracją scen dziennych, wieczornych oraz zacienionych (np. tunele).
- Nasycenie i jasność ($\tilde{S}, \tilde{V}$) tworzą wyraźne grupy punktów – jedna z nich o niskich wartościach obu zmiennych, odpowiadająca prawdopodobnie ciemnym i matowym scenom.



Rysunek 4: Rozkład danych w przestrzeni trójwymiarowej $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$ – widoki 3D (góra) i rzuty 2D (dół). Kolor punktów odpowiada wartości $\tilde{V}$.


Wnioski z tej wizualizacji były pomocne przy projektowaniu późniejszych metod klastrowania. Potwierdziły również potencjał nawet prostego, 3-wymiarowego wektora cech $\vec{f}_2$ do oddzielania różnych typów scen.

2.3 Klastrowanie KMeans z wykorzystaniem wektora cech

W osobnym eksperymencie przeprowadzono klastrowanie danych reprezentowanych przez trójwymiarowy wektor cech $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$, zawierający medianę barwy, nasycenia i jasności dla każdego obrazu. Taka reprezentacja jest bardzo zwarta (tylko 3 cechy), ale niesie kluczowe informacje na temat dominujących kolorów w górnej części obrazu.

Aby oszacować optymalną liczbę klastrów k , obliczono dwa wskaźniki: **inercję** (suma


odległości punktów od centroidów) oraz **Silhouette Score**. Ich przebieg przedstawiono na Rys. 5.



Rysunek 5: Analiza optymalnej liczby klastrów na podstawie inercji i wskaźnika silhouette dla wektora $\vec{f}_2$.

Klasyfikacja oparta na $\vec{f}_2$ pozwoliła na uzyskanie następujących klas:

- **Klaster 0** – obrazy z wyraźnie błękitnym niebem,
- **Klaster 1** – sceny z szarym, zachmurzonym niebem lub niskim nasyceniem barwy,
- **Klaster 2** – obrazy zawierające przeszkody lub zabudowania zamiast nieba,
- **Klaster 3** – ciemne sceny odpowiadające porze nocnej lub tunelom.



Rysunek 6: Wyniki KMeans dla wektora $\vec{f}_2$: wizualizacja 3D klastrów i ich etykiet interpretacyjnych.

Przykładowe obrazy z każdego klastra przedstawiono poniżej. Dzięki prostocie wektora $\vec{f}_2$, separowalność scen była zaskakująco dobra, mimo ograniczonej liczby cech.




Rysunek 7: Wybrane obrazy z czterech klastrów (KMeans, $\vec{f}_2$). Klasy odpowiadają kolejno: niebieskiemu niebu, szaremu niebu, przeszkodom oraz nocy/tunelowi.

Eksperyment ten potwierdził, że nawet przy bardzo zwartej reprezentacji, możliwe jest uzyskanie dobrze interpretowalnych klastrów – o ile cechy są dobrze dobrane i oddzielają kluczowe cechy sceny (barwa, jasność, nasycenie).

2.4 Klastrowanie DBSCAN z wykorzystaniem wektora 3-elementowego


W kolejnym eksperymencie klastrowania zastosowano algorytm DBSCAN na danych zredukowanych do trójwymiarowego wektora $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$. Podejście to miało na celu sprawdzenie, czy nawet przy minimalnej liczbie cech możliwe jest uzyskanie naturalnych skupień bez potrzeby określania liczby klastrów.

Wybór parametru eps oparto o klasyczny wykres odległości do 5 najbliższych sąsiadów. Jak pokazano na Rysunku 8, zauważalne załamanie krzywej następuje w okolicy wartości $\text{eps} \approx 0.014$, co zostało przyjęte jako punkt wyjściowy do eksperymentów.




Rysunek 8: Wykres 5-NN dla danych z wektorem $\vec{f}_2$ – wybór parametru eps .

Wyniki klastrowania z wybranym $\text{eps} = 0.014$ i domyślnym $\text{MinPts} = 5$ przedstawiono na Rys. 9. Na wizualizacjach zaznaczono zarówno wszystkie punkty (łącznie z szumem), jak i tylko punkty przypisane do właściwych klastrów.



Rysunek 9: Wyniki klastrowania DBSCAN dla $\vec{f}_2$ – u góry: zidentyfikowane 3 klastry, u dołu: 2 klastry. Po lewej – wszystkie punkty, po prawej – tylko klastry (bez szumu).




Rysunek 10: Więcej wyników klastrowania DBSCAN dla $\vec{f}_2^-$.

Niestety, niezależnie od konfiguracji parametrów, wyniki nie były satysfakcjonujące. Algorytm:

- traktował ponad 90% próbek jako **szum**,
- znajdował niewielkie, ciasne klastry w silnie ograniczonym fragmencie przestrzeni cech,
- generował **klastry trudne do zinterpretowania** – jak pokazano na Rys. 11, nie były one jednoznacznie powiązane z kolorystyką nieba, przeszkodami ani warunkami oświetleniowymi.

Trudne do interpretacji klastry




Rysunek 11: Przykładowe obrazy przypisane do klastrów DBSCAN – brak spójności semantycznej.

Z powyższych powodów uznano, że **DBSCAN nie nadaje się do klastrowania** danych reprezentowanych przez $\vec{f}_2$ – pomimo jego zalet w wykrywaniu nieregularnych skupień, wymaga on znacznie bardziej zróżnicowanej przestrzeni cech, niż zapewnia mediana HSV. W przeciwieństwie do KMeans, DBSCAN nie był w stanie rozpoznać i oddzielić scen z niebem, przeszkodami czy nocą.

2.5 Klastrowanie metodą Warda z wykorzystaniem wektora 3-elementowego


W celu sprawdzenia działania podejścia hierarchicznego zastosowano metodę Warda na danych reprezentowanych przez trójwymiarowy wektor cech $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$. Algorytm ten umożliwia analizę struktury danych bez potrzeby wcześniejszego określania liczby klastrów – bazując na minimalizacji wzrostu wariancji przy łączeniu grup.

Na podstawie dendrogramu (Rys. 12) rozważono trzy potencjalne poziomy cięcia drzewa: 3, 4 oraz 5 klastrów.




Rysunek 12: Dendrogram wygenerowany metodą Warda dla danych z wektorem $\vec{f}_2$. Widoczne potencjalne cięcia na 3–5 klastrow.

Podział na 3 klastry prowadził do zbyt ogólnych grup – trudno było jednoznacznie oddzielić np. sceny z szarym i niebieskim niebem.



Rysunek 13: Wizualizacja klastrowania Warda na 3 klastry – brak wyraźnego podziału między różnymi typami nieba.


Podział na 5 klastrów zapewniał dużą szczegółowość, jednak prowadził do nieco „rozcłódkowanych” grup, trudnych do jednoznacznej interpretacji.



Rysunek 14: Wizualizacja klastrów przy 5 klasach – struktura złożona, ale mniej intuicyjna.

Najlepsze rezultaty uzyskano przy **podziale na 4 klastry**, gdzie zauważalne były cztery sensowne grupy:


- **Klaster 1 (pomarańczowy)** – sceny z zabudowaniami lub neutralnym tłem, często bez wyraźnego nieba,
- **Klaster 2 (fioletowy)** – ciemne sceny (noc/tunel),
- **Klaster 3 (niebieski)** – jasne sceny z błękitnym niebem,
- **Klaster 4 (zielony)** – szare niebo, warunki pochmurne.



Rysunek 15: Wizualizacja 4 klastrów metodą Warda – dobre rozdzielenie typów scen przy użyciu $\vec{f}_2$.

Podział ten potwierdzają również próbki obrazów z każdego klastra (Rys. 16). Widać wyraźnie, że algorytm poradził sobie z separacją scen o odmiennych cechach barwowych, mimo wykorzystania jedynie median HSV.


Klaster 1
(3077 obrazków)



Klaster 2
(1365 obrazków)



Klaster 3
(3416 obrazków)



Klaster 4
(36554 obrazków)



Rysunek 16: Przykładowe obrazy przypisane do poszczególnych klastrów – klasy odpowiadają błękitowi, szarościom, nocy i przeszkodom.

W porównaniu do DBSCAN i nawet KMeans, metoda Warda na wektorze $\vec{f}_2$ okazała się bardzo skuteczna – szczególnie biorąc pod uwagę ograniczoną liczbę cech. Klasy były zwarte, dobrze separowalne i interpretowalne wizualnie.

2.6 Klastrowanie KMeans z wykorzystaniem wektora 7-elementowego

Ostatnim z testowanych podejść było zastosowanie algorytmu KMeans do danych opisanych siedmiowymiarowym wektorem cech $\vec{f}_1$. Ten wariant uwzględniał zarówno statystyki przestrzeni HSV, jak i relacje między kanałami w RGB:

$$\vec{f}_1 = \left[\overline{V}, \sigma_V, \text{IQR}_{RGB}, \frac{G}{R}, \frac{G}{B}, \overline{S}, \overline{H} \right]$$

Taka reprezentacja miała na celu uchwycenie bardziej złożonych zależności w danych – w tym informacji o rozrzucie wartości RGB oraz proporcjach kanałów, które są charakterystyczne np. dla błękitnego nieba.

Do klastrowania ponownie przyjęto wartość $k = 4$, aby móc porównać wyniki z poprzednimi eksperymentami. Podział danych okazał się bardzo podobny do tego uzyskanego przy użyciu wektora $\vec{f}_2$. Próbkę z poszczególnych klastrów przedstawiono na Rys. 17.

Klaster 0
(4640 obrazków)



Podobna interpretacja klastrów



Klaster 1
(31423 obrazków)



Klaster 2
(6716 obrazków)



Klaster 3
(1633 obrazków)

Rysunek 17: Wyniki KMeans dla wektora $\vec{f}_1$ – interpretacja klastrów bardzo zbliżona do poprzednich wariantów.

Zidentyfikowane klastry można przypisać do następujących kategorii:

- **Klaster 0** – jasne sceny z błękitnym niebem,
- **Klaster 1** – dominacja szarości, pochmurne niebo lub zamglenie,
- **Klaster 2** – przesłonięcie przez zabudowania lub wysokie obiekty,
- **Klaster 3** – sceny ciemne, najprawdopodobniej nocne lub z tuneli.

Warto zauważyć, że mimo większej liczby cech, podział nie różnił się istotnie od tego uzyskanego z pomocą $\vec{f}_2$, co sugeruje, że proste statystyki HSV wystarczają do separacji wizualnych klas w tym konkretnym problemie.

Dodatkowe cechy RGB (takie jak IQR i proporcje kanałów) mogły poprawić separowalność danych w granicznych przypadkach, jednak nie wpłynęły znacząco na interpretację końcowych klastrów.

3 Podsumowanie i wnioski

Celem niniejszego projektu była eksploracyjna analiza skupień wybranych klatek z nagrań wideo z kamer samochodowych. Główne pytanie badawcze dotyczyło tego, czy możliwe jest zidentyfikowanie logicznych i interpretowalnych klastrów scen na podstawie dominujących kolorów w górnej części obrazu, które najczęściej odpowiadają niebu lub zabudowaniom.

Najważniejsze obserwacje

- Najlepsze rezultaty klastrowania uzyskano przy wykorzystaniu algorytmu **KMeans** i podziale na **cztery klastry**, co umożliwiło wyodrębnienie następujących kategorii:
 1. błękitne niebo,
 2. szare niebo / chmury,

3. ciemne sceny (noc / tunel),
 4. zabudowania i inne przeszkody w górnej części obrazu.
- Reprezentacje cech opierające się na przestrzeni **HSV** okazały się wystarczające do skutecznego grupowania danych. Nawet bardzo kompaktowy wektor $\vec{f}_2 = [\tilde{H}, \tilde{S}, \tilde{V}]$ umożliwił uzyskanie przejrzystych klastrów o sensownej interpretacji.
 - Wektor $\vec{f}_1$, zawierający dodatkowe cechy z przestrzeni RGB (takie jak IQR i proporcje kanałów), nie przyniósł wyraźnej poprawy jakości podziału, ale potwierdził stabilność wyników.
 - Algorytm **DBSCAN**, mimo swojej zdolności do detekcji nieliniowych struktur i odrzucania punktów szumowych, nie sprawdził się w analizowanym przypadku. Ponad 90% próbek było oznaczanych jako szum, a znalezione klastry były małe i trudne do interpretacji.
 - Metoda **Warda** (klastrowanie hierarchiczne) dostarczyła rezultatów porównywalnych z KMeans, szczególnie przy podziale na cztery klastry. Jej dodatkową zaletą była możliwość eksploracji struktury danych na różnych poziomach szczegółowości.

Wnioski ogólne

Projekt potwierdził, że stosunkowo prosta reprezentacja danych wizualnych, ograniczona do górnych partii obrazu i przekształcona do przestrzeni HSV, wystarcza do skutecznego klastrowania scen drogowych. Zastosowanie filtracji opartej na współczynniku zmienności (CV) dodatkowo poprawiło jakość ekstrakcji cech.

Wyniki mogą być traktowane jako punkt wyjścia do bardziej zaawansowanych analiz – np.:

- klasyfikacji pory dnia,
- detekcji pogorszenia widoczności,
- pośredniej oceny warunków atmosferycznych.

Dodatkowo, dominacja scen z szarym niebem może skłaniać do hipotez nt. warunków pogodowych w analizowanym okresie nagrań, jednak nie należy nadinterpretować tego w kontekście jakości powietrza – ze względu na ograniczoną rozdzielczość i percepcyjne zniekształcenia kamery.

Kierunki dalszych badań

Możliwości rozszerzenia projektu obejmują m.in.:

- użycie głębszych cech wizualnych (np. embeddingów CNN),
- automatyczne etykietowanie scen na podstawie danych GPS / czasu / pogody,
- analizę zmian klas w czasie (ciągłość klastrów w wideo),
- testowanie innych algorytmów klastrowania (np. HDBSCAN, GMM).

Uzyskane rezultaty pokazują, że prosta analiza kolorystyczna może stanowić skuteczne narzędzie eksploracyjne dla danych wideo, nawet w przypadku zastosowania bardzo ograniczonych cech wejściowych.